

CUA-Lark · 让大模型像人一样操作飞书桌面端



所属赛道：飞书 AI 校园竞赛 · 质量工程与智能测试方向

课题一句话：构建一个 Computer-Use Agent (CUA)，借助视觉多模态大模型，像真实用户一样操作飞书桌面客户端，完成跨产品的自动化功能测试与质量评估。

一、课题背景

1.1 CUA 技术趋势

Computer-Use Agent (CUA) 是当前 AI 领域最具前沿性的研究方向之一。CUA 能够像人类用户一样，通过“看”屏幕、“想”策略、“做”操作，实现对桌面应用程序的自主操控。2025 年以来，OpenAI CUA、Anthropic Computer Use、字节跳动 UI-TARS 等产品和模型相继推出，标志着这一技术从实验室走向实际应用。

1.2 测试领域的痛点

传统 GUI 自动化测试高度依赖 DOM 结构、元素选择器或 Accessibility Tree。面对 UI 频繁迭代时十分脆弱——一次按钮位置调整或文案变更就可能大量测试脚本失效。基于视觉多模态模型的 CUA 方法，可以像真实用户一样通过视觉理解界面语义并执行操作，天然具备更强的泛化性和鲁棒性，有望从根本上改变 GUI 测试的范式。

1.3 飞书：理想的测试场景

飞书作为字节跳动旗下的企业级协作套件，涵盖 IM 即时通讯、日历、云文档、多维表格、视频会议、邮箱等丰富的子产品线。飞书桌面客户端（Electron 架构）的 UI 复杂度高、交互模式多样、子产品间联动频繁，是 CUA 技术落地到测试领域的理想实验场。

二、课题目标

设计并实现一个 **CUA-Lark 智能测试Agent**，核心能力包括：

- 视觉感知**：通过屏幕截图识别飞书桌面应用的 UI 元素、界面状态和布局结构
- 语义理解**：理解自然语言测试指令，将其拆解为可执行的操作序列
- 自主操作**：通过模拟鼠标点击、键盘输入、滚动等操作完成测试任务
- 状态验证**：操作执行后，通过视觉比对或语义判断验证结果是否符合预期

5. 评估报告：自动生成测试执行报告，包含操作轨迹、成功率、耗时等关键指标

三、技术要求与建议方案

3.1 系统架构设计（必做）

参赛选手需设计一个完整的 CUA 测试框架架构，建议包含但不限于以下模块：

模块	职责	技术举例
视觉感知层	屏幕截图采集、UI 元素识别与定位	截图 API + VLM（GPT-4o / Claude 3.5 Sonnet / Qwen-VL / UI-TARS）
规划决策层	将自然语言指令拆解为步骤序列	LLM 推理 + CoT（Chain of Thought）规划
执行操作层	模拟鼠标、键盘等人机交互操作	PyAutoGUI / NutJS / 系统级 API
状态验证层	执行后截图比对，判断操作是否成功	VLM 语义比对 / 像素级 Diff / OCR 校验
评估报告层	汇总测试结果，生成可视化评估报告	自定义 Dashboard / Markdown 报告

3.2 核心功能实现（必做）

A. 基础操作能力

- 支持对飞书桌面客户端的基础 GUI 操作：单击、双击、右键、拖拽、滚动、文本输入、快捷键组合
- 支持多步骤复合操作的串联执行（如：打开聊天 → 搜索联系人 → 发送消息 → 验证发送成功）

B. 飞书功能覆盖（至少覆盖 2 个子产品）

子产品	建议测试场景示例
IM 即时通讯	发送文本/图片消息、创建群组、@提及、搜索消息记录、表情回复
日历 Calendar	创建日程、邀请参会人、修改日程时间、查看忙闲状态
云文档 Docs	创建文档、编辑文本内容、插入标题/列表、分享文档

多维表格 Base	创建表格、添加字段、录入数据、切换视图
视频会议 VC	发起会议、加入会议、开关摄像头/麦克风
邮箱 Mail	撰写邮件、添加附件、发送与回复

C. 自然语言驱动测试

支持通过自然语言描述测试用例，例如：

- "在飞书中创建一个名为'项目周报'的新文档，并输入标题'2026年Q2项目进展'"
- "打开日历，创建一个明天下午2点的会议，邀请张三参加"
- "在IM中搜索'测试群'，发送一条消息'Hello World'，并确认发送成功"

3.3 进阶能力（加分项）

进阶能力	说明
异常场景处理	自动识别并应对弹窗干扰、权限不足提示、加载超时等异常
跨产品联动测试	如 IM 收到日历邀请 → 跳转日历确认 → 返回 IM 验证状态
自愈式执行	操作失败后自动分析原因，尝试替代路径完成任务
测试用例自动生成	基于飞书功能文档或录屏，自动生成结构化测试用例
混合定位策略	视觉识别 + Accessibility Tree / DOM 信息融合，提升元素定位精度
多轮对话编排	根据中间执行结果，动态调整后续测试步骤
录制回放	录制人工操作轨迹，生成可复用的自动化脚本

3.4 渐进式实现路径（建议）

为帮助选手合理规划开发节奏，建议按以下里程碑推进：

阶段	目标	验收标准
M1 · 单步操作	实现截图 → VLM 识别 → 单步点击/输入	能在飞书上完成 5 个单步操作
M2 · 流程串联	实现多步操作串联 + 状态验证	能完成 1 个子产品的 3 条端到端测试流程

M3 · 多产品覆盖	扩展到 3 个以上子产品	在 IM/Calendar/Docs 三个子产品上各有 2+ 可运行用例
M4 · 评估体系	搭建评测框架，输出结构化报告	能自动统计成功率、耗时、步骤数等核心指标
M5 · 进阶优化	异常处理、自愈、跨产品联动等	至少实现 1-2 项进阶能力

四、参考资料

4.1 推荐开源项目

项目	说明	参考价值
UI-TARS-desktop	字节跳动开源的多模态 GUI Agent 桌面应用	架构设计、Operator 接口、SDK 二次开发
UI-TARS	端到端视觉-语言-动作模型，OSWorld SOTA	VLM 模型调用、Prompt 设计、坐标后处理
TuriX-CUA	多 Agent 架构（Planner + Executor + Evaluator）	Multi-Agent 分工设计、MCP 协议集成
opencli	将网站和 Electron 应用 CLI 化	非视觉路径参考、Electron 控制思路
OSWorld	操作系统级 Agent 评测 Benchmark	评测方法论、用例设计思路

4.2 推荐论文

- UI-TARS: Pioneering Automated GUI Interaction with Native Agents (ByteDance, 2025)
- OS Agents: A Survey on MLLM-based Agents for Computer, Phone and Browser Use (ACL 2025 Oral)
- ScaleCUA: Scaling up Computer Use Agents (ICLR 2026 Oral)
- GUI-R1: A Generalist R1-Style Vision-Language Action Model For GUI Agents

4.3 赛方提供的技术资源

- 飞书开放平台文档：<https://open.feishu.cn/>（获取飞书 API 能力，辅助理解产品功能边界）
- 飞书桌面客户端：<https://www.feishu.cn/download>

- **Coding Plan x ArkClaw**：提供 AI 编程辅助工具额度，加速代码开发效率

五、交付要求

5.1 决赛提交

序号	产物	要求
1	系统设计文档	架构图、模块说明、技术选型理由、数据流图
2	源代码仓库	GitHub 仓库，含完整可运行代码、README、安装指南
3	Demo 视频	3-5 分钟，展示多个飞书子产品的操作测试能力
4	评测报告	基于标准用例集的完整评测数据与分析
5	答辩 PPT	15 分钟演讲 + 5 分钟 Q&A

5.2 技术栈建议（不限制）

- **编程语言**：Python / TypeScript / 混合均可
- **VLM 模型**：GPT-4o / Claude 3.5+ / Qwen-VL / UI-TARS / 其他多模态模型
- **操作控制**：PyAutoGUI / NutJS / 系统原生 API
- **框架选择**：可基于 UI-TARS-desktop SDK 二次开发，也可完全自研

六、FAQ

- Q1：是否必须使用特定的多模态模型？** 不限制。举例 GPT-4o、Claude 3.5 Sonnet、Qwen-VL 或 UI-TARS 等具备强视觉理解能力的模型，也可使用开源模型本地部署。
- Q2：飞书桌面客户端的操作环境是什么？** 赛方将提供标准化测试环境（macOS / Windows）。飞书桌面客户端基于 Electron 架构，选手也可在自己设备上开发。
- Q3：可以结合非视觉方式（Accessibility Tree / DOM）辅助定位吗？** 可以，且鼓励探索融合方案。但核心操作决策必须基于视觉多模态理解，不可完全依赖结构化信息。

Q4：可以基于现有开源项目二次开发吗？ 可以。鼓励站在巨人肩膀上创新，但需在文档中明确标注引用来源，并说明自研创新点。

Q5：评测时的模型 API 如何保障？ 赛方将在决赛阶段提供统一 API Key 和网络环境。初赛期间选手使用自有资源。

Q6：团队规模和分工有要求吗？ 建议 2-4 人组队。鼓励分工明确：如模型调优、操作执行、评测体系、前端可视化等方向各有专人负责。